חלק א

הכנת נתונים:

ראשית, ביצענו טיפול בערכים החסרים, כאשר בחרנו לטפל בכל עמודה בנפרד:

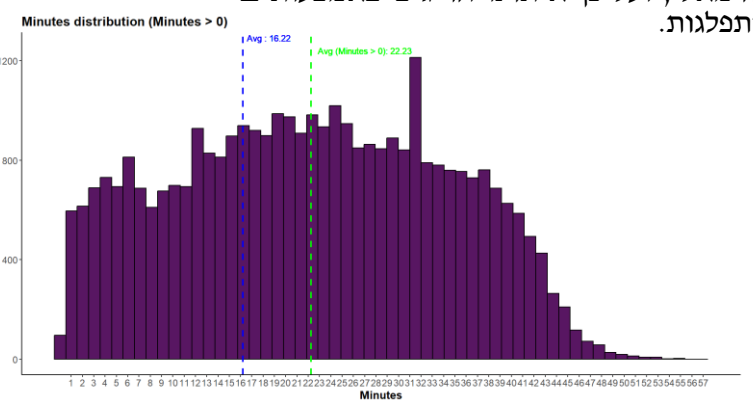
- points: כלל הערכים החסרים בעמודה זו, היו ברשומות בהן התקיים played=0. קרי, השחקנים לא שיחקו כלל, ועל כן הגדרנו את הערכים הללו להיות 0, כי לא ייתכן שהשחקן קלע נקודות במשחק שלא שיחק בו.
- Game importance: היו 5,682 ערכים חסרים. בחרנו למלא את הערכים הללו בערך החציוני (6) על מנת להימנע ממחיקה של רשומות ולהימנע מעיוות יתר של הנתונים.
- permovingaverage: היו 3,095 ערכים חסרים. על מנת למלא את הערכים הללו, יצרנו מזהה ייחודי עבור כל שחקן המבוסס על הכפלת שכרו, גובהו ומשקלו (אשר מעוגל ל-7 מקומות עשרוניים). מכיוון שהדיוק מאחורי הנקודה העשרונית הוא גבוה, היה זה סביר בעיננו להניח שנצליח לסווג בשיטה זו את מרבית השחקנים באופן ייחודי. לבסוף תהליך זה הביא ל-600 מזהים ייחודיים, כמות שחקנים הגיונית בהתחשב בכמות הרשומות הקיימות ב-dataset. עבור כל אחד מהמזהים (=שחקנים) הללו, חישבנו את ממוצע ה-permovingaverage שלהם ומילאנו את הערכים החסרים בממוצע זה. עבור שחקנים שכלל ערכי ה-permovingaverage שלהם היו ריקים, החלפנו את ה-null בממוצע הכללי של עמודה זו. גישה זו אפשרה לנו להימנע ממחיקת רשומות תוך מילוי הרשומות בערכים אשר סביר להניח כי אינם מעוותים את ה-dataset בצורה משמעותית.

לאחר מכן, הוספנו מספר משתנים ל-dataset כדי שיסייעו לנו בניתוח ובהפקת תובנות לאורך המטלה. המשתנים החדשים שהוספנו הם:

- PPM (נקודות לדקת משחק): מספר הנקודות הממוצע ששחקן קלע לדקת משחק, מדד אשר מעיד על יעילות הקליעה של שחקן ביחס לדקות משחק.
- BMI (מדד מסת הגוף): מדד שימושי להבנת מצבו הגופני והבריאותי של השחקן. המדד מבוסס על גובה השחקן ומשקלו, ועשוי להעיד על ביצועי השחקן.
- Overweight: משתנה בינארי המציין האם שחקן סובל מעודף משקל או אם לאו על סמך ה-BMI שלו, כאשר BMI גבוה מ-25 נחשב לעודף משקל (בהתאם לסטנדרטים בריאותיים בינלאומיים).
- Lottery pick: בליגת ה-NBA 14 הבחירות הראשונות בדראפט הן בחירות לוטרי, כאשר הסיבה לכך היא שרוצים לאפשר איזון בליגה, כך ש-14 הקבוצות שלא עלו לפלייאוף בעונה יכולות "להתחמש" בשחקנים הכישרוניים ביותר במחזור. בהתאם לשיטה זו, משתנה בינארי זה מציין האם השחקן נבחר בבחירת לוטרי בדראפט (קרי ה-draft שלו הוא בטווח 1-14).
- משתנה דמי עבור העמדות השונות – סנטר וגארד, כאשר הסרנו את פורוורד.

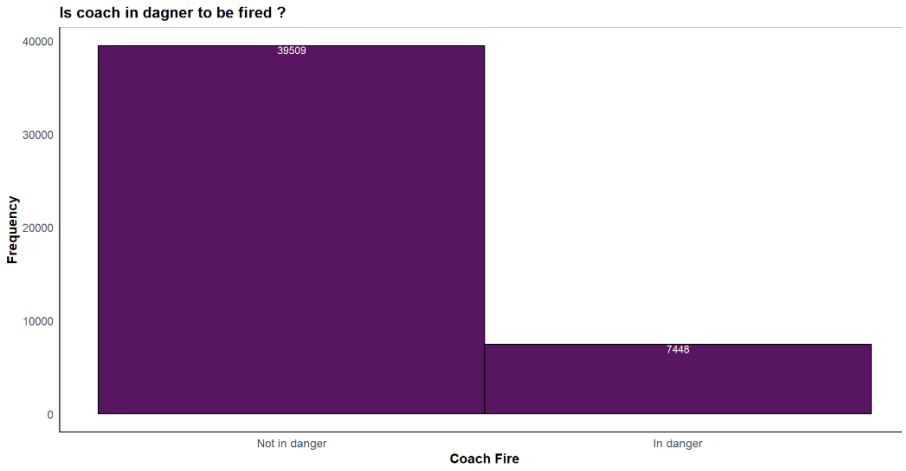
לאחר צעדים אלו, פנינו לטיפול בערכים חריגים. במשתנים הבינאריים הדאטה איננו מתפלג בצורה אחידה, אך הנחנו שזה משקף את המציאות וכי הדאטא מאוזן, ולפיכך לא שינינו את הערכים הללו. להלן המשתנים הנומריים אשר איתרנו בהם חריגים:

- points: ברוב המשחקים שחקנים לא קולעים מעל 40 נקודות, במיוחד לא שחקנים שנה ראשונה ושניה, ולכן מחקנו 19 תצפיות חריגות של שחקנים שקלעו יותר מ-40 נקודות.
- Permovingaverage: ישנם מספר ערכים חריגים משני צידי הסקאלה (כאשר במשתנה זה ישנם גם ערכים שליליים). לאחר מספר ניסיונות להסיר חריגים באמצעות טרנספורמציות שונות ואלגוריתמים כגון IQR, העדפנו להשאיר את הדאטא כמות שהוא כיוון שלא היינו מרוצים מתוצאות השינויים אשר לא הועילו במיוחד בהסרת החריגים וגרמו לעיוות משמעותי בדאטא.
- Salary: ישנם שחקנים אשר מקבלים שכר גבוה במיוחד ולכן הם נחשבים לחריגים, אך בהתאם אלו שחקנים שבאופן כללי מקבלים יותר דקות משחק. כלומר זהו אינדיקטור חזק לכך שהשחקן משחק יותר דקות, ולכן גם במקרה זה בחרנו להשאיר את הערכים החריגים כמות שהם.
- BMI: בעל ערכים חריגים ומתפלג יחסית באופן נורמאלי, ועל כן איתרנו חריגים באמצעות Z-score method ומילאנו אותם בערך הממוצע של ההתפלגות.

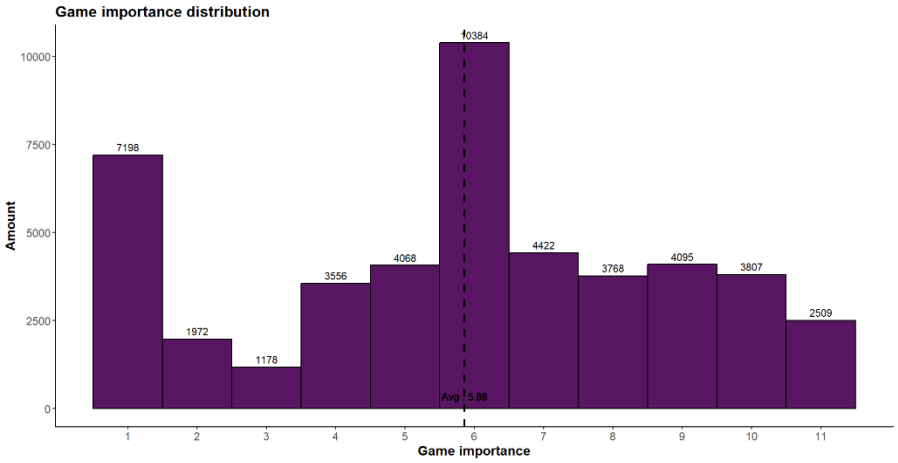


סטטיסטיקה תיאורית

בגרף ניתן לראות את התפלגות הדקות למשחק. ממוצע הדקות הינו 16.22 דקות, כאשר 12,692 תצפיות עומדות על 0 דקות. במידה ומתחשבים רק בשחקנים ששיחקו בפועל, ממוצע הדקות למשחק הוא 22.23 דקות. זוהי התפלגות עם זנב שמאלי. (יש לציין כי מטעמי נוחות הגרף איננו משקף את הרשומות אשר מכילות אפס).



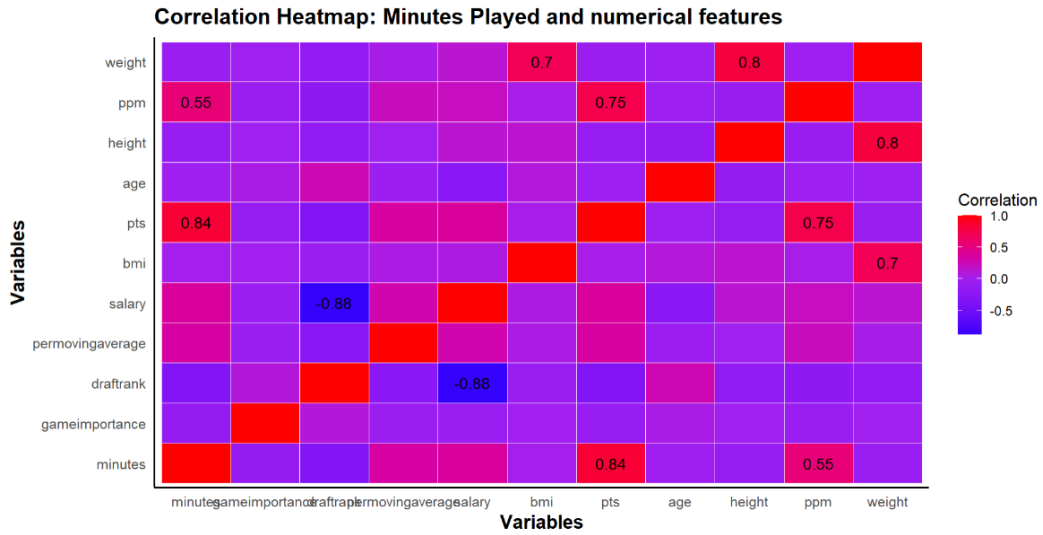
בגרף ניתן לראות את התפלגות המשחקים בהם המאמן היה בסכנת פיטורים. כאשר רק ב-16% מהמשחקים המאמן היה בסכנת פיטורים. דבר אשר מקשה לענות על שאלת המחקר, שכן זה מהווה אחוז נמוך מכלל התצפיות אשר ברשותנו.

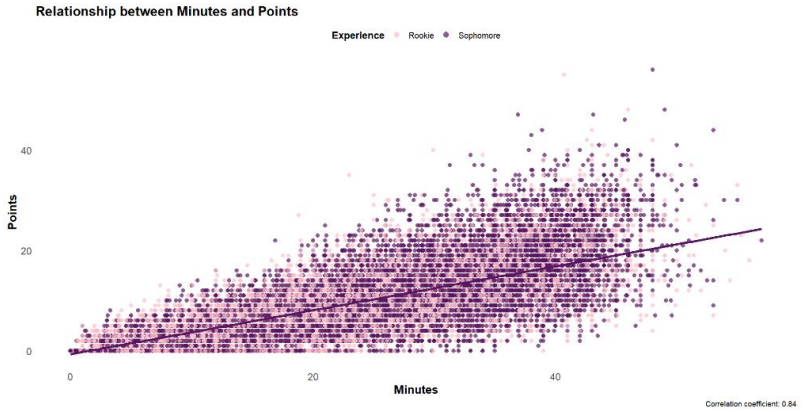


בגרף ניתן לראות את התפלגות חשיבות המשחקים, ממוצע חשיבות המשחק הינו 5.86 והחציון הוא 6. 2,509 משחקים סווגו כמשחקים חשובים ביותר. ניתן לראות כי חשיבות 6 וחשיבות 1 חריגות באופן בו הן רווחות ב-dataset. מבחינת המשחקים בחשיבות 1, ייתכן שזה משקף את המציאות, וייתכן שזה מצביע על כך שה-dataset איננו מאוזן. מבחינת ערכי ה-6, מצב זה קורה כי אנחנו בחרנו למלא את הערכים החסרים בערך זה.

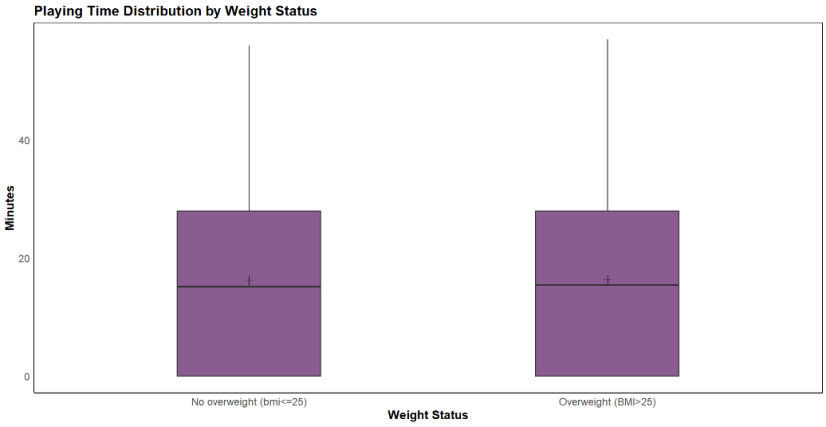
קשרים בין משתנים:

מטה מוצגת מפת חום בין כלל המשתנים הנומריים הקיימים, וממנה ניתן להצביע על מספר נקודות מעניינות. ראשית, קיים מתאם שלילי חזק בין שכר לבין מיקום בדראפט. מתאם זה הגיוני שכן שחקנים שנבחרים במקום גבוה יותר מרוויחים טוב יותר. לדוגמא בדראפט 2023 האחרון, ויקטור וומבניאמה שנבחר ראשון יתוגמל במשכורת של כ-10 מיליון דולר והבחירה ה-30 יתוגמל בכ-2 מיליון דולר בלבד. שנית, נמצא מתאם חיובי חזק בין דקות לנקודות. ממצא זה מתיישב עם ההיגיון שכן ככל ששחקן משחק יותר דקות משחק יש לו יותר הזדמנות לקלוע נקודות. כמוכן, מדד ה-PPM מתואם באופן חיובי עם דקות משחק וגם עם נקודות, ממצא אותו מראש שכן PPM מוגדר להיות היחס בין נקודות לדקות. לבסוף ניתן לראות שמשקל וגובה נמצאים בקורלציה גבוה, זהו גם כן ממצא צפוי שכן בקרב שחקני כדורסל אשר נמצאים בכושר שיא, גובה ומשקל צומחים יחדיו לרוב.

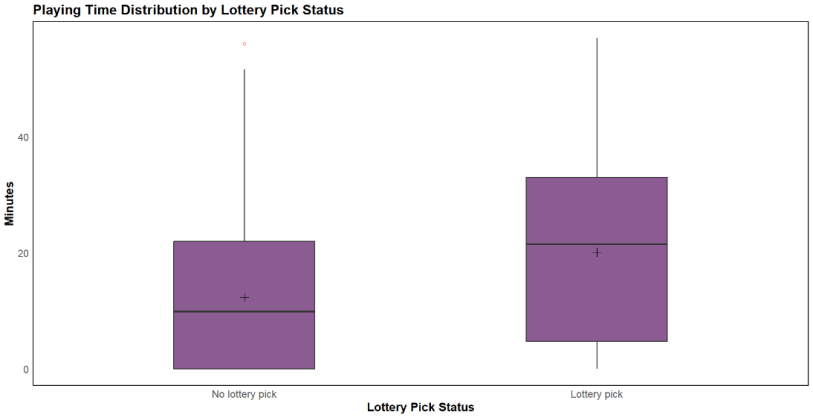




בהמשך למפת החום בחרנו להעמיק בקשר בין דקות לנקודות. כיוון שכפי שניתן לראות קיים מתאם חיובי חזק של 0.84 בין השניים, ומכך הסקנו שקשר זה חשוב בעת הרצת מודלים שונים. בנוסף לכך ניסינו לנתח כיצד הניסיון של השחקן משפיע על מספר הנקודות שהוא קולע ועל מספר הדקות שבהן הוא נמצא במגרש. מהתבוננות בגרף, ניתן לראות כי נראה שהניסיון איננו מהווה פקטור משמעותי כלל, שכן צבעי הנקודות מפוזרים על פני כל הגרף כולו.



לאחר הוספת המשתנה BMI ביקשנו לבחון האם העובדה שהשחקן סובל מעודף משקל משפיעה על זמן דקות המשחק שלו, אך מהגרף ניכר שאין הבדל כזה, ועל כן הסקנו ש-Overweight הוא משתנה מיותר אשר לא יתרום להסבר כמות דקות המשחק.



כאמור מעלה, הוספנו משתנה של בחירת לוטרי. מן הגרף ניתן להסיק ששחקנים שנבחרו בלוטרי משחקים בממוצע יותר דקות, וכמעט תמיד משחקים במשחק, לעומת זאת שחקנים שאינם לוטרי עלולים להישאר על הספסל מספר רב של משחקים. בנוסף ניתן לראות שישנם מעט חריגים מלמעלה בקרב אלו שלא נבחרו בלוטרי, ואנו משערים כי תופעה זו קורית מכיוון שלפעמים חיזוי יכולת השחקנים אינו מספיק טוב ושחקנים מעולים נבחרים בבחירות מאוחרות יותר, ומשחקים המון על אף שלא נבחרו בלוטרי. כך לדוגמא ניתן לראות את טוני פארקר (28) , קרלוס בוזר (35) ורוג'ן רונדו (21) אשר לבסוף נבחרו כולם ל-All stars .

חלק ב

כדי לבחון את שאלת המחקר: האם מאמני NBA שנמצאים בסיכון לפיטורים נוטים לא לתת לשחקנים צעירים לשחק במשחקים, במיוחד במשחקים חשובים, השתמשנו במודל הפרש ההפרשים.
תחילה אמדנו את המודל הבסיסי (1):

$$played = \beta 0 + \beta 1 * coachfire + \beta 2 * gameimportance + \beta 3 * (coachfire * gameimportance) + \varepsilon$$

ולאחר מכן הוספנו משתנים מפקחים נוספים כגון: עמדות, ניסיון, משכורת, מיקום בדראפט ועוד (כפי שיפורט מטה).

	Dependent variable:	
	played	
	(1)	(2)
coachfire	0.073***	0.072***
	(0.012)	(0.011)
gameimportance	-0.008***	-0.006***
	(0.001)	(0.001)
draftrank		-0.003***
		(0.001)
permovingaverage		0.010***
		(0.0004)
salary		0.045***
		(0.004)
guard		0.049***
		(0.004)
center		-0.082***
		(0.006)
exp		0.024***
		(0.004)
coachfire: gameimportance	-0.010***	-0.011***
	(0.002)	(0.002)
Constant	0.776***	0.596***
	(0.005)	(0.016)
Observations	46,957	46,957
R^2	0.005	0.065
Adjusted R^2	0.005	0.065
Residual Std. Error	0.443 (df = 46953)	0.430 (df = 46947)
F Statistic	86.324*** (df = 3; 46953)	361.050*** (df = 9; 46947)
Note:		*p**p***p<0.01

<u>פרשנות המודל :</u>

<u>coachfire</u> : מובהק בשני המודלים. משמעות המקדם היא שבהינתן יתר המשתנים מוחזקים קבוע, לשחקן שמאמנו בסכנת פיטורים הסתברות גבוהה יותר לשחק של 7.3 נקודות האחוז.

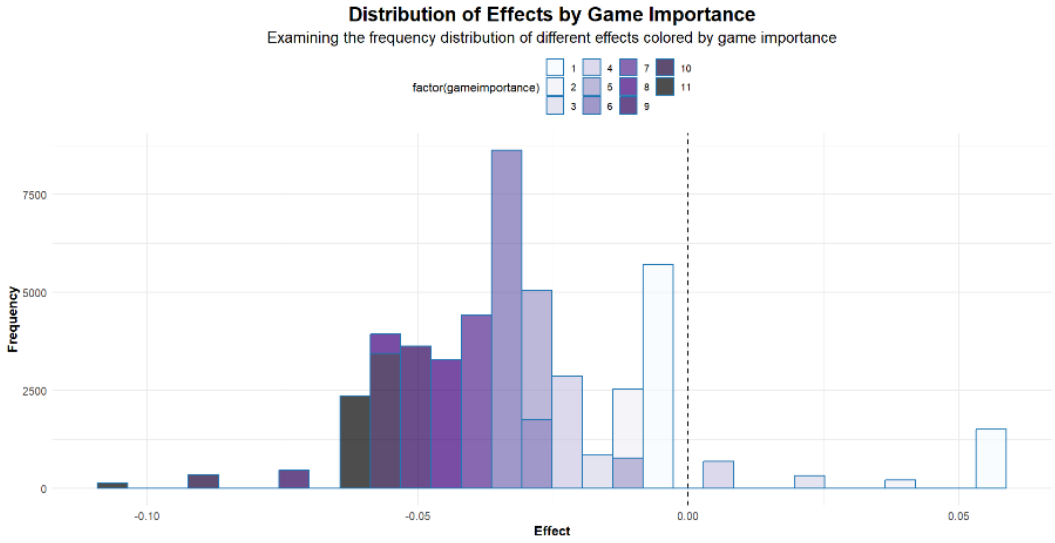
<u>gameimportance</u> : המקדם שלילי ומובהק סטטיסטית בשני המודלים, עובדה שעולה בקנה אחד עם ציפיות החוקרים, כיוון שזה מצביע על כך שלשחקן צעיר יש סיכוי נמוך יותר לשחק במשחקים חשובים. כלומר, בהינתן יתר המשתנים מוחזקים קבוע כאשר חשיבות המשחק גדלה ב-1 (10%) ההסתברות לשחק נמוכה יותר ב-0.8 נקודות האחוז.

<u>coachfire: gameimportance</u> : מקדם זה מובהק בשני המודלים. זה מחזק את הממצא שההשפעה השלילית של סיכון הפיטורים של מאמן על משחק של שחקנים צעירים בולטת יותר במשחקים חשובים, דבר שתומך בהשערה שהוצגה במאמר.

<u>משתנים דמוגרפים נוספים</u> : קבוצת הבסיס במודל 2 היא פורוורדים ועל כן ניתן לראות שההסתברות לשחק גדלה כאשר השחקן הוא גארד וקטנה במידה הוא סנטר. כמו כן בחירה מאוחרת יותר בדראפט מקטינה את ההסתברות לשחק. בנוסף שיננו את נתון המשכורת להיות במיליוני דולרים ועל כן עליה של מיליון דולר במשכורת מעלה אתה ההסתברות לשחק ב-4.5 נקודות האחוז (בהינתן שאר המשתנים מוחזקים קבוע).

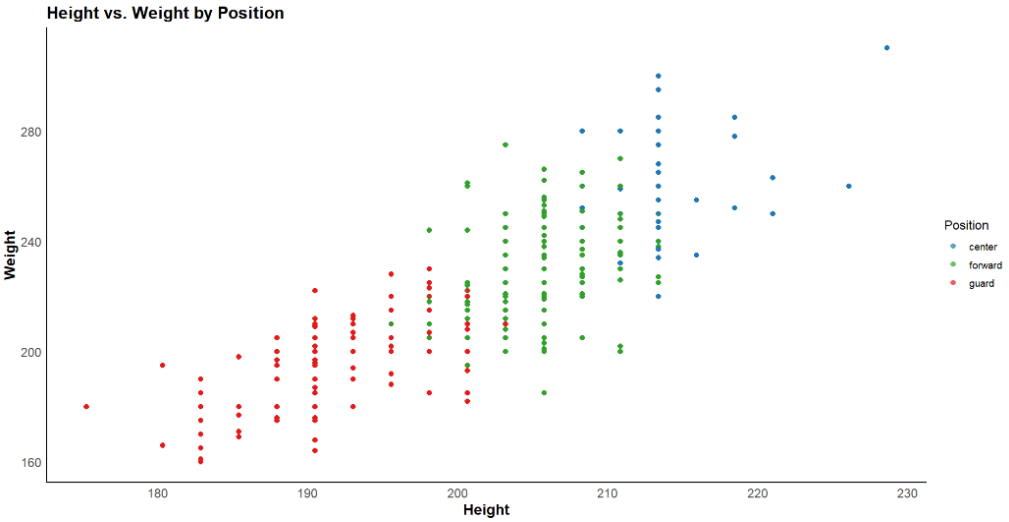
<u>דיון :</u>

אמנם ההשפעה של המשתנה סכנת פיטורים היא חיובית אך כאשר המשחק חשוב במיוחד ההשפעה הזאת מתבטלת. כלומר, ניתן לראות שכאשר המשחק ברמת חשיבות הגבוהה מ-4, ההשפעה הכוללת של מאמן בסכנת פיטורים וחשיבות משחק יהיו שלילים. כמוכן, בהסתכלות על הגרף מטה ניתן לראות את ההשפעה הכוללת של חשיבות המשחק, סכנת פיטורים והאינטראקציה ביניהם. מהגרף למדים שעבור מרבית התצפיות האפקט הוא שלילי. כמוכן, ניתן לראות שככל שהמשחק פחות חשוב השפעה זו דועכת. על כן ניתן לקבוע שהמודל תומך בהשערות החוקרים ואכן שחקנים צעירים משחקים פחות כאשר המאמנים שלהם נמצאים בסכנת פיטורים והמשחק הינו חשוב.



<u>חלק ג :</u>

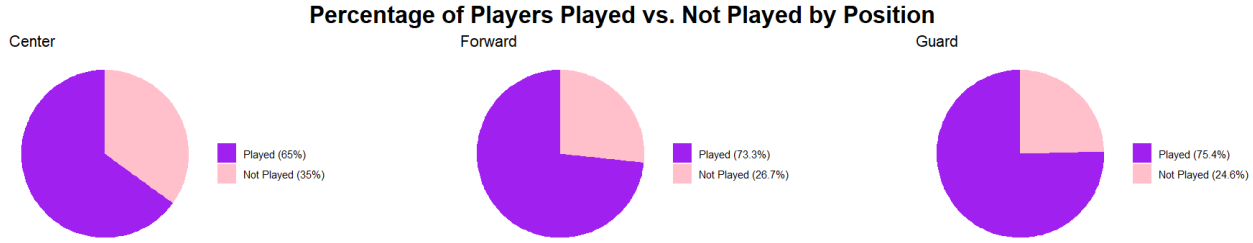
עמדות כדורסל מורכבות מ-3 עמדות מרכזיות : גארד, סנטר ופורוורד ; כאשר לכל עמדה תפקיד ייחודי. הגארדים לרוב מטפלים בעיקר בכדור ומנהלים את ההתקפה של הקבוצה, ומראים יכולת מסירה והובלת כדור. לעומתם, סנטרים הם בדרך כלל השחקנים הגבוהים ביותר, ואחראים בעיקר על הגנה ומתבלטים בד״כ בריבאונדים וחסימות וקליעה מתחת לסל. פורוורדים הם שחקנים ורסטיליים בעלי שילוב של כישורים שונים ונחשבים לשחקנים מגוונים.



לרוב הגארדים הם השחקנים הנמוכים והקטנים יותר בעוד הסנטרים הם השחקנים הגדולים יותר. וכפי שניתן לראות בגרף מטה, גם המדגם שלנו מתפלג בהתאם לכך, והבדלי המשקל והגובה בין השחקנים בעמדות השונות ניכרים מאוד. בהתאם הערכנו כי אלו שני משתנים אשר יהיו משמעותיים מאוד לאלגוריתם Kmeans.

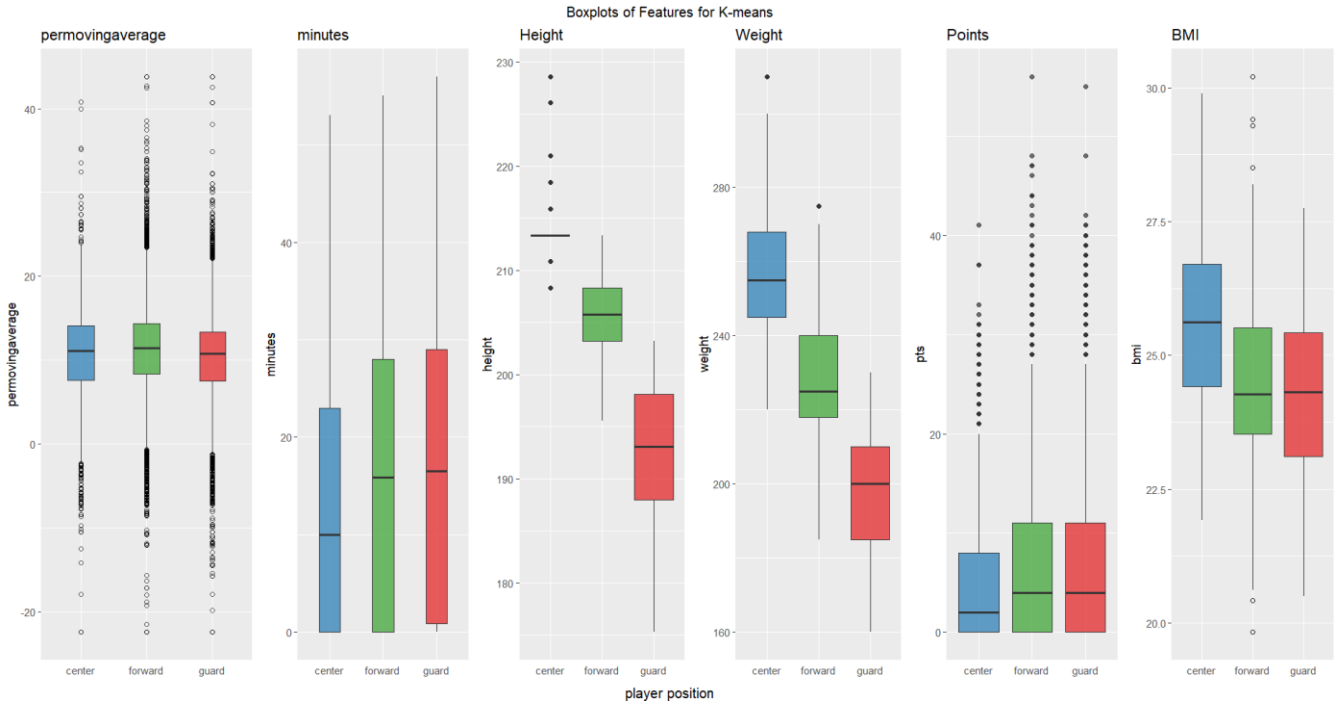
	ממוצע דקות	ממוצע נקודות	ממוצע מדד
גארד	**17.178**	**7.630**	10.275
פורוורד	16.313	7.461	**11.373**
סנטר	12.916	6.104	10.669
כלל העמדות	16.220	6.418	10.831

כפי שניתן לראות בטבלה, בבחינת ממוצעים לפי עמדות גארדים משחקים הכי הרבה דקות, לאחר מכן פורוורדים ולבסוף סנטרים. כמו כן, בהתאם לכך בממוצעי הנקודות נצפית מגמה דומה. לעומת זאת, בבחינת מדד הביצועים, פורוורדים רשמו את הממוצע הגבוה ביותר, לאחר מכן סנטרים ולבסוף גארדים. ייתכן שמגמה זו נובעת מכך שהמדד מסתמך על מדדי כדורסל נוספים ומשכלל את כלל נתוני המשחק, ובנוסף גארדים מובילים בעיקר את הכדור ועל כן יכולים לבצע יותר טעויות כגון איבודי כדור אשר יורידו להם נקודות מבחינת המדד.



לאחר שמצאנו כי המשתנים: played, weight, height, minutes, permovingaverage, points הם גורמים אשר מאפיינים באופן שונה את עמדות השחקנים השונות, הסקנו כי סביר שגם BMI מהווה משתנה שיאפיין באופן שונה כל קבוצה. בחרנו לשקף את ההבדלים הללו ב-BOXPLOTS שכן על מנת לשפר את ביצועי האלגוריתם KMEANS יש צורך לטפל בחריגים, ואלו גרפים אשר מאפשרים לשקף חריגים בצורה נוחה. יש לציין שבחלק זה איתרנו חריגים תוך התחשבות בהפרדה לעמדות, וזאת בשונה מהסרת החריגים הכללית שבוצעה בחלק א'.

[1] ESPN- NBA draft 2023



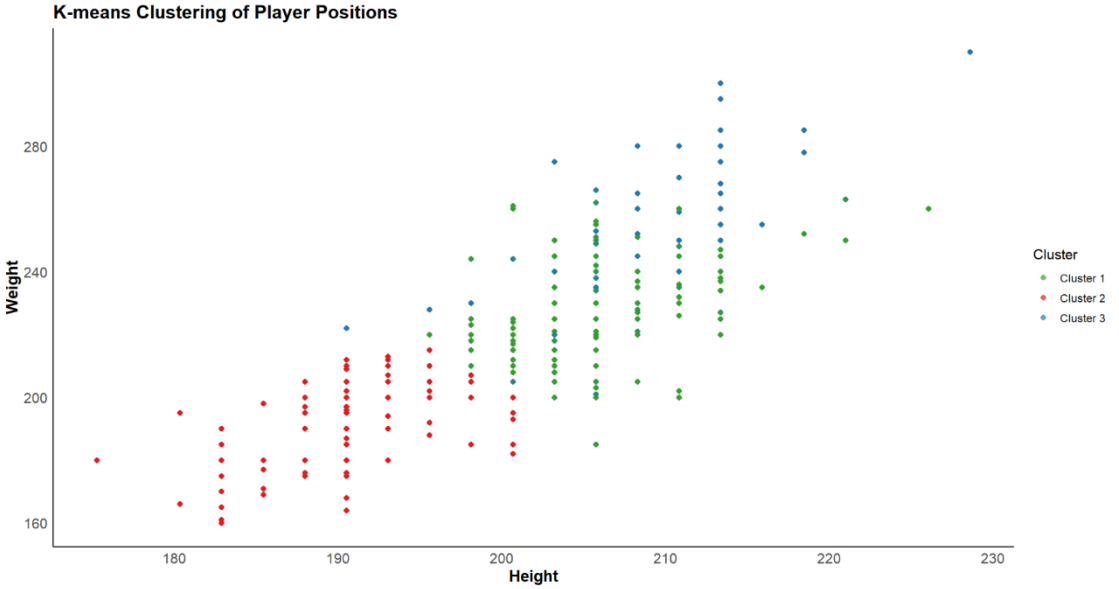
מהתרשימים ניתן לראות שבכלל המאפיינים שצוינו לעיל יש הבדלים בין הקבוצות (לפחות עמדה אחת שונה מן השאר), וניתן להבחין כי ה-BMI של סנטרים גבוה יותר משל השאר. זה ככה״נ נובע בגלל הדרישה לפיזיות גבוהה עבורם תפקידם ההגנתי המשמעותי.

טיפול בערכים חריגים בחלוקה לעמדות:

- permovingaverage: בעל ערכים שליליים ובעל חריגים רבים בכל העמדות, לכן הפעלנו עליו טרנספורמציית arcsin אשר מתאימה לטיפול בחריגים בהינתן קיומם של ערכים שליליים. לאחר פעולה זו נותרו פחות תצפיות חריגות, אך עדיין נותרו כאלה, ולמרות זאת החלטנו להסתפק במצב, כדי להימנע מלהמשיך ולעוות את הדאטא.
- Height: בעמדת הסנטר מוצבים שחקנים גבוהים במיוחד וקיימת ביניהם שונות גדולה. מאפיין משמעותי של קבוצה זו הוא שהשחקנים הגבוהים במיוחד משתייכים אליה, ולכן עשינו שימוש ב-Winsorization capping תוך קיצוץ חריגים בעיקר מלמטה ופחות מלמעלה.
- points: מלא בערכים חריגים מלמעלה, זאת עקב העובדה שיש משחקים שבהם שחקנים לא משחקים כלל. כאמור לעיל, לערך אפס יש משמעות מיוחדת – כיוון שהוא מרמז על כך שהשחקן לא שיחק כלל, והראינו כי זה דבר אשר נפוץ יותר בקרב סנטרים. בתחילה חשבנו להשאיר את הדאטא כפי שהוא על מנת להימנע מעיוות הדאטא, אך לאחר מספר ניסויים עם Kmeans, בחרנו לבצע טרנספורמציית לוג לכלל הערכים מלבד אפס, על אף שהדבר מעט מעוות את הנתונים.
- Minutes, Weight, BMI: עם תצפיות חריגות מעטות יחסית ולכן בחרנו להשאירם.

לאחר הטיפול בחריגים ונרמול הערכים, הפעלנו את האלגוריתם בעזרת כלל הפיצ׳רים שצוינו לעיל כמבדילים בין הקבוצות. מדדנו את תוצאות האלגוריתם עפ״י המדדים ARI ו-Silhouette, והגענו לתוצאות האופטימליות ביותר בעת שימוש בפיצ׳רים הבאים בלבד: height, weight, BMI, permovingaverage. ברור מאוד מדוע המשתנים אשר נוגעים לגובה ומשקל השפיעו באופן חיובי ומכריע על ביצועי האלגוריתם (כפי שציינו לעיל), אך קשה להבין מדוע Pts ו-minutes לא תרמו לפעולת הקלסיפיקציה שכן הם מהווים גורם מפריד משמעותי בין הסנטרים לבין שאר העמדות. אנו מעריכים שהעובדה שהמשתנה played קשור באופן חזק ל-Pts היא זו שגרמה לכך שהאלגוריתם לא נעזר בו בצורה שהשפיע חיובית על תוצאותיו.

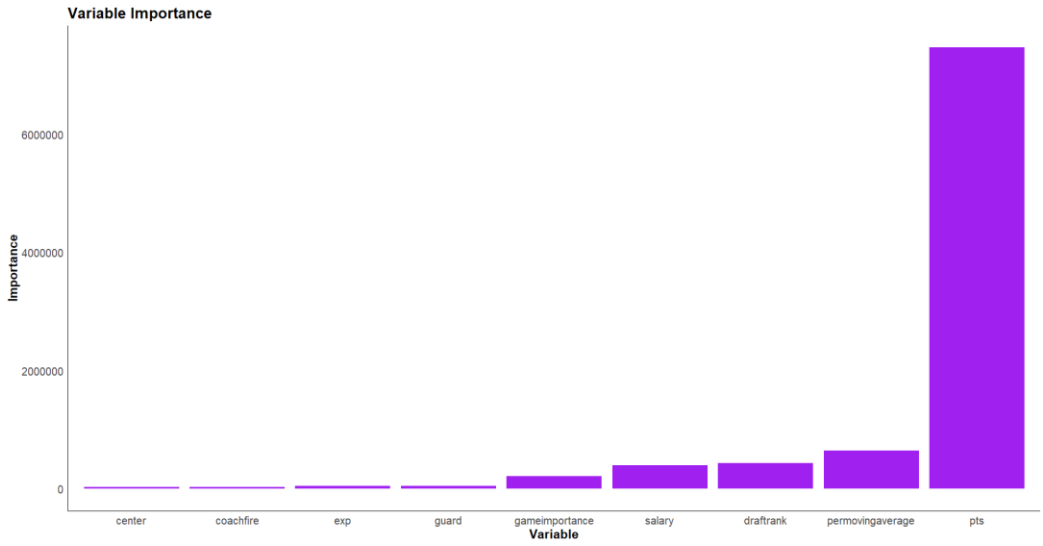
להלן גרף המציג את הקלאסטרים לאחר הרצת אלגוריתם K-means:



ניתן לראות בהשוואה לתרשים הקודם שהאלגוריתם חילק את הקבוצות באופן יחסית טוב, כאשר הוא התקשה לסווג תצפיות חריגות.

חלק ד :

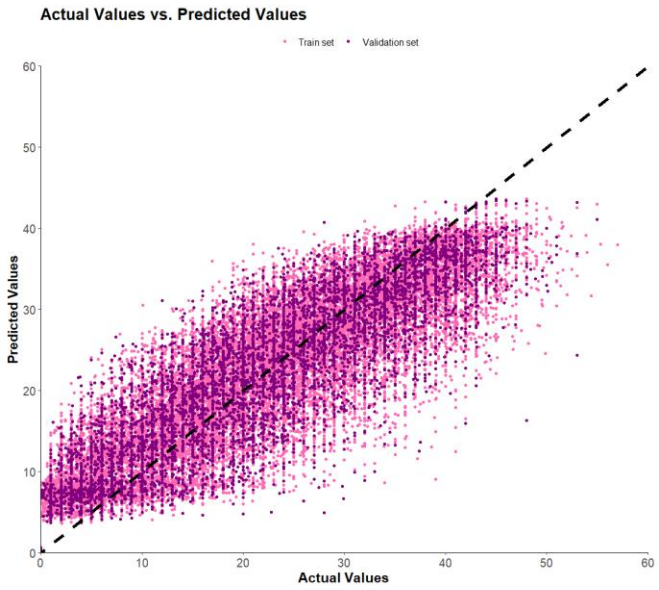
בחרנו במודל Random Forest מבין המודלים שנלמדו בקורס בשל מגוון יכולותיו הכוללות בין היתר: Feature importance, התמודדות עם ערכים חריגים ולכידת דפוסי נתונים מורכבים.
תחילה הרצנו את המודל על כלל המשתנים כדי שנוכל לקבל תמונת מצב כללית כיצד המודל מעריך את החשיבות של כל אחד מן הפיצ׳רים, ויצרנו את התרשים מטה אשר מתאר את החשיבות שהעניק המודל לכל אחד מן הפיצ׳רים.



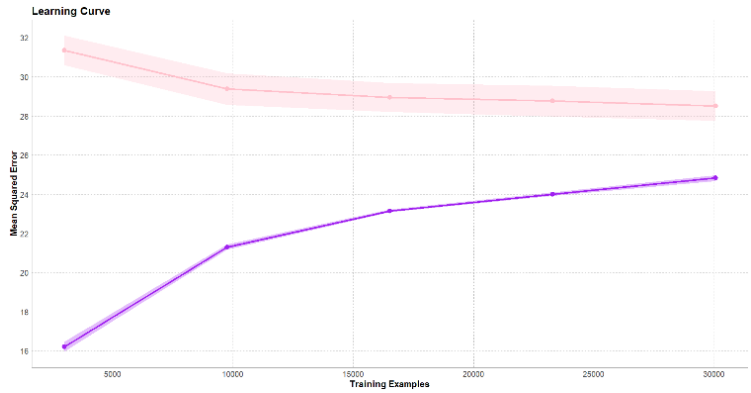
לאחר מכן הרצנו אלגוריתמי Forward Feature Elimination ו-Backward Feature Elimination, על מנת שיסייעו לנו להחליט אילו ממדים הינם פחות רלוונטיים למודל. האלגוריתמים הללו הצביעו על כך שכדאי להסיר את המימדים: lotterypick ,age, weight, coachfire ואת כלל המימדים אשר נוגעים לפוזיציית השחקנים. בחרנו לפעול בהתאם לתוצאות אלגוריתמים אלו, כיוון שהם תאמו באופן כמעט מלא את החשיבות שהעניק המודל לפיצ׳רים השונים (כפי שניתן לראות בתרשים מעלה).

כיוון שכאשר played=0 אזי חובה שיתקיים minutes=0, התלבטנו האם בכלל כדאי לאפשר למודל ללמוד על המקרים שבהם played=0 – כיוון שאנחנו איננו זקוקים ללמידה על מנת לחזות את תצפיות אלו. אך חשבנו שייתכן שהמודל יצליח לנצל את התצפיות הללו (אשר מהוות כ-25% מהדאטא) כדי להפיק תובנות על התנהגות שאר הפיצ'רים. לבסוף החלטנו להריץ את המודל על כל הדאטא ובנפרד להריץ אותו על רשומות שבהן played=1 בלבד, ולהבין בדיעבד באמצעות ה-MSE איזה מודל מספק תוצאות טובות יותר. זאת כאשר לאחר ביצוע הפרדיקציה, שינינו את כלל ערכי הפרדיקציות שבהן played=0 לאפס מוחלט.

ביצענו מספר הרצות של מודל Random forest וביצענו תהליך של אופטימיזציה על ידי שינוי ההיפר-פרמטרים השונים תוך שימוש ב-Cross validation על מנת להימנע מ-Overfitting, ובאמצעות מציאת ההיפר-פרמטרים האופטימליים תוך שימוש ב-Gridserach. התוצאה הייתה שעדיף לאפשר לאלגוריתם ללמוד על ה-dataset כולו, מאשר רק על המקרים בהם played=1.



מהתרשים ניתן לראות כי סט הוולידציה והאימון חולקו באופן ראוי וכי הם דומים במאפיינים שלהם, כמוכן ניתן להבחין שהמודל בייחוד איננו מצליח לחזות זמן משחק של שחקנים אשר שיחקו במשך זמן רב יחסית (מעל 40 דקות). משחקי כדורסל ב-NBA נמשכים 48 דקות ושחקנים לרוב לא משחקים כמות זו של דקות. על כן, אם הדאטה היה מאפשר זאת היינו מנסים לסווג אילו משחקים הם משחקים שבהם הייתה הארכה.למשתנה זה לדעתנו יכלה להיות השפעה רבה על כמות הדקות ששחקן שיחק. כמו כן, מההתפזרות של הנקודות על פני הגרף באופן רחב יחסית ניתן להסיק כי המודל לא הצליח ללמוד בצורה מספיק מדויקת את הדאטא, אך לאחר מספר רב של ניסיונות, אנו מסיקים שזה נובע מאיכות הדאטא ולא מ-Underfitting אשר דורש שינויים במודל. ייתכן כי ישנם מודלים אשר לא נלמדו בקורס ומסוגלים להתמודד עם הדאטא בצורה טובה יותר.



מתרשים עקומת הלמידה שיצרנו עבור המודל הסופי, ניתן לראות כי ה-MSE של סט הוולידציה יורד ככל שאנו משתמשים ביותר תצפיות וכי מנגד ה-MSE של סט האימון עולה ככל שמוסיפים תצפיות. השילוב של השניים מעיד כי אנחנו מצליחים להימנע מ-Overfitting, אך שייתכן כי אנחנו לא מצליחים ללמוד בצורה טובה מהדאטא ועל כן ה-MSE נותר גבוה. לחלופין, כיוון ש-MSE הוא מאוד תלוי בדאטא שמקבלים מלכתחילה ובקשר שלו אל המשתנה הנחזה, ייתכן שבהינתן הדאטא שקיבלנו זהו ציון MSE טוב יחסית. כמוכן יש קפיצה מאוד משמעותית בהתחלה ב-MSE של סט האימון, וזה ככל הנראה עקב כך שעם מעט דאטא המודל עדיין איננו מצליח לתפוס את מורכבויות הדאטא, ועדיין סובל מ-Overfitting.

לבסוף החלנו את כלל המניפולציות שביצענו בסט האימון על סט הטסט (הסרת החריגים, הסרת עמודות ומילוי הערכים החסרים), וביצענו פרדיקציה.